



HYENA CHO TIẾNG VIỆT

Mô hình ngôn ngữ tích chập dài dưới bậc hai, phân tích ablation và khởi tạo bộ lọc từ cấu trúc thông tin của corpus

Bài báo nền: Poli et al., [Hyena Hierarchy](#), ICML 2023 (Oral)

Báo cáo cuối kỳ, môn Chuyên đề nghiên cứu và Xử lý ngôn ngữ tự nhiên

Nhóm 08

Nguyễn Cao Trung Kiên · Tô Huỳnh Minh Tiến · Trần Tú Quang

University of Information Technology, VNU-HCM (UIT) · 2026



1. **Bài toán & ba giả thuyết:** vì sao thử Hyena trên tiếng Việt
2. **Phương pháp:** đo cấu trúc thông tin $I(d)$, ánh xạ sang bộ lọc, thiết lập công bằng
3. **Kết quả:** E1 chất lượng · E2 token hoá · E3 ablation · E4 khởi tạo · E5 hiệu năng · E6 recall
4. **Hạn chế & kết luận**



1

Bài toán & giả thuyết

Chữ Quốc ngữ viết rời theo âm tiết · chuỗi dài hơn
chi phí bậc hai $O(L^2)$ chi phối khi L tăng

Phần 1



- Bài báo gốc chỉ thực nghiệm trên **tiếng Anh**.
- Chữ Quốc ngữ viết **rời theo âm tiết**: cùng một nội dung, chuỗi tiếng Việt **dài hơn**.
- Chuỗi càng dài, chi phí bậc hai $O(L^2)$ của attention càng **chi phối** tổng chi phí, nên lợi thế dưới bậc hai của Hyena đáng giá hơn với tiếng Việt.

H1. Cùng ngân sách token, Hyena có giữ được chất lượng so với Transformer trên tiếng Việt?

H2. Lợi thế đó có **lớn hơn** khi token hoá theo âm tiết so với BPE?

H3. Khoảng suy giảm α của bộ lọc, siêu tham số **không được bài báo gốc đặc tả**: có nên **đo từ corpus** thay vì chọn tay?



$$z_t^{n+1} = x_t^n \cdot (h^n * z^n)_t, \quad n = 1 \dots N$$

- Thay attention bằng **tích chập dài** (kernel dài bằng chuỗi, tính qua FFT, $O(L \log L)$) xen kẽ **cổng nhân theo phần tử**.
- Bộ lọc h **tham số hoá ngầm**: FFN nhỏ + kích hoạt sine + **cửa sổ suy giảm mũ** $\exp(-\alpha t)$; mỗi kênh một α , tức một **độ dài hiệu dụng**.
- Phân bố α quyết định bộ nhớ của mô hình nằm ở khoảng cách nào $\rightarrow$ chính là chỗ H3 can thiệp.

bậc N = 1 $\approx$ GSS

• bậc N = 2 $\approx$ H3 của Dao et al. (cấu hình chính)

• bậc N = 3



2

Phương pháp

Đo $I(d)$ trên corpus · ánh xạ sang α · thiết lập so sánh công bằng

Phần 2



corpus $\rightarrow I(d)$: thông tin tương hỗ giữa token cách nhau $d \rightarrow$ chuẩn hoá thành khối lượng $w(d) \rightarrow$ độ dài hiệu dụng $\ell \rightarrow \alpha = L / \ell$

- Ước lượng plug-in có **trừ độ chệch** bằng xáo trộn; công cụ được **hiệu chuẩn** trên chuỗi tổng hợp biết trước đáp án.
- Tiếng Việt giữ tín hiệu trên nền nhiễu tới $d = 167$; gấp **1,7–2,3 lần** tiếng Anh ở khoảng cách ngắn ($d \leq 13$), giảm dần về ≈ 1 ở $d = 167$.
- **80–90%** khối lượng thông tin (tùy ngôn ngữ và bộ token hoá) nằm trong 34 token đầu, trong khi khởi tạo `uniform` mặc định đặt **toàn bộ** 256 kênh xa hơn 64 token.

Quy ước phải khai: chuẩn hoá trên **lưới log** không nhân bề rộng ô. Có trọng số bề rộng, trung vị độ dài hiệu dụng đổi từ **2,95** $\rightarrow$ **90,5** token (VI-BPE). Kết quả PPL không đổi, nhưng cách diễn giải "thông tin nằm trong ~ 3 token" phụ thuộc quy ước này.



Ràng buộc	Giá trị
Kiến trúc chung	4 lớp $\cdot d_{\text{model}} = 256 \cdot L = 512$ · từ điển 16k · chỉ khác toán tử trộn token
Tham số	Hyena 7.553.280 · Transformer 7.383.552 · lệch 2,30%
Dữ liệu	Wikipedia VI/EN, nhánh EN cắt xuống đúng 38.250.964 token của VI
Ngân sách	cùng 49.995.776 token huấn luyện = 6.103 bước $\approx 1,31$ epoch mỗi nhánh
Seed	3 seed cho E1/E2/E4 · 2 seed cho E3 · KTC 95% phân phối t

- **67 phép kiểm tự động**, gồm kiểm chứng nhân quả: rò rỉ tương lai $< 10^{-15}$ trên mọi biến thể; bản cố tình sai vọt lên $9,1 \times 10^{-1}$, tức bộ test bắt được lỗi thật.
- Kết luận khoa học so với đối chứng công bằng `logspace`, không so với hình nộm `uniform`.



3

Kết quả

E1 chất lượng · E2 token hoá · E3 ablation · E4 khởi tạo bộ lọc · E5 hiệu năng · E6 recall

Phần 3



Ngôn ngữ	Hyena (PPL)	Transformer (PPL)	Hyena thấp hơn
Tiếng Việt	51,38 [51,05; 51,71]	63,86 [63,14; 64,58]	19,5%
Tiếng Anh (cùng số token)	55,82 [54,96; 56,68]	65,43 [64,99; 65,87]	14,7%

- Khoảng tin cậy hai mô hình **tách rời rõ** trên cả hai ngôn ngữ → **H1 đúng vững**.
- Lợi thế trên tiếng Việt (19,5%) **lớn hơn** tiếng Anh (14,7%), đúng chiều dự đoán từ cấu trúc thông tin.

Hai nhánh nhìn thấy đúng **cùng một lượng tín hiệu**: 38.250.964 token duy nhất, 49.995.776 token huấn luyện, 6.103 bước, nên chênh lệch chỉ còn quy được cho ngôn ngữ.



Token hoá (tiếng Việt)	Tỉ lệ PPL Transformer/Hyena
Âm tiết (chuỗi dài hơn)	1,243
BPE (chuỗi ngắn hơn)	1,202

- PPL **không so sánh được** giữa hai từ điển khác nhau, chỉ so được **tỉ lệ giữa hai mô hình trong cùng từ điển**.
- Lợi thế Hyena lớn hơn ở âm tiết, đúng chiều H2, nhưng chênh lệch nhỏ và chưa có KTC cho tỉ lệ: **dấu hiệu, chưa phải bằng chứng**.



Cấu hình	PPL	Δ	KTC 95%	Tách rời?
Gốc (bậc 2, đủ)	51,38		[51,05; 51,71]	
Bỏ cửa sổ suy giảm	53,30	+1,92	[52,24; 54,35]	có
Bậc N = 1	53,11	+1,73	[51,72; 54,49]	có*
Bỏ kích hoạt sine	51,80	+0,42	[51,49; 52,10]	không
Bậc N = 3	51,63	+0,25	[49,51; 53,76]	không
Bỏ positional emb	50,79	-0,59	[50,14; 51,45]	không

- **Cửa sổ suy giảm là thành phần sống còn**, đúng vai trò của $\text{Window}(t)$; đây cũng là nơi giả thuyết H3 tác động.
- *N = 1: tách rời nhưng biên chỉ hở **0,016 PPL**, và nhánh này mất 331.776 tham số (-4,4%), thiệt hại trộn hai nguyên nhân nên kết luận mong manh.
- Bỏ positional embedding **không gây hại**: bộ lọc tích chập đã mang sẵn thông tin vị trí.



Khởi tạo	VI (PPL, KTC)	EN cùng số token (PPL, KTC)
uniform	51,38 [51,05; 51,71]	55,82 [54,96; 56,68]
logspace	50,48 [50,33; 50,62]	54,97 [54,56; 55,37]
corpus (H3)	50,19 [49,93; 50,45]	54,91 [54,53; 55,29]

- **Tiếng Việt:** logspace và corpus đều **tách rời** khỏi uniform ($-0,90 / -1,19$ PPL) → **khoảng** α thực sự quan trọng, chọn tùy tiện gây thiệt hại đo được.
- **Tiếng Anh:** cùng chiều ($-0,85 / -0,91$ PPL) nhưng KTC **chồng lấn** do phương sai seed của uniform lớn.
- **corpus vs logspace** : chỉ hơn 0,285 (VI) / 0,052 (EN) PPL, chồng lấn cả hai → **không kết luận được H3**.

Kết quả **âm có kiểm soát**: đo α từ corpus không tốt hơn một lựa chọn cách đều theo log. Đây vẫn là câu trả lời có giá trị cho siêu tham số không được bài báo gốc đặc tả.



- Ở $L = 8192$, Hyena nhanh hơn kernel attention tiết kiệm bộ nhớ **1,88 lần** (lướt tiến và lùi); attention dày đặc hết bộ nhớ từ trước đó.
- Bộ nhớ Hyena tăng xấp xỉ **gấp đôi khi L gấp đôi** (gần tuyến tính); attention tăng gấp bốn (bậc hai).
- Đổi lại, ở $L = 512$ mỗi token của Hyena **chậm hơn 1,51 lần** Transformer (91,7–92,5k so với 138,5–138,6k token/giây, Kaggle T4); chi phí cố định của FFT chỉ được bù khi $L \geq 8K$.

Kết luận hiệu năng: lợi thế dưới bậc hai là **lợi thế tiệm cận**: có thật, đo được, nhưng chỉ xuất hiện ở ngữ cảnh dài.



- Tác vụ truy hồi key-value tổng hợp ($L = 65$, vocab 10): attention giải **hoàn hảo** (1,000 ở mọi seed).
- Hyena: phân bố **lượng cực**. Gộp 5 seed: $0,092 \cdot 0,141 \cdot 0,922 \cdot 0,981 \cdot 0,987$. **3/5 lần thành công ($\geq 0,92$), 2/5 lần sập ($\leq 0,14$)**, không có giá trị trung gian.
- Gấp đôi ngân sách bước làm lần thành công tốt lên ($0,92 \rightarrow 0,98$) nhưng **không cứu được kiểu hỏng** → thất bại tối ưu hoá lượng cực, không phải hội tụ chậm.

Với phân bố lượng cực, báo mean $\pm$ sd là **sai lệch** vì không lần chạy nào nằm gần trung bình. Nhóm báo **tỉ lệ thành công + độ chính xác khi thành công**.



4

Hạn chế & kết luận

Những gì nhóm biết là chưa chắc · và những gì đứng vững

Phần 4



1. **Quy ước lưới l(d):** chuẩn hoá trên lưới log không nhân bề rộng ô; trung vị độ dài hiệu dụng nhảy với quy ước ($2,95 \leftrightarrow 90,5$ token).
2. **KTC chỉ bắt nhiều khởi tạo:** 3 seed (2 với ablation) trên một tập test duy nhất, không bootstrap; nền nhiều l(d) dựng từ **một** lần xáo trộn.
3. **Lệch đơn vị:** α đo trên corpus BPE nhưng huấn luyện bằng âm tiết (lệch thang $\sim 6,5\%$ VI, $\sim 18,5\%$ EN).
4. **Chưa so cùng thời gian thực:** Hyena chậm hơn $1,51\times$ /token $\rightarrow$ cùng giờ GPU, Transformer thấy nhiều token hơn.
5. **Mẫu dữ liệu phụ thuộc phiên bản datasets :** nhánh EN phải lấy mẫu lại (110k tài liệu, cắt về đúng ngân sách VI); phiên bản thư viện nay được ghi vào mọi artifact.



Đúng vững: Hyena đạt PPL thấp hơn Transformer **19,5%** (VI) và **14,7%** (EN) ở cùng ngân sách token; cửa sổ suy giảm là thành phần sống còn; **khoảng** α quan trọng (`logspace` vượt `uniform` tách rời trên tiếng Việt); tăng tốc $1,88\times$ ở $L = 8192$.

Không kết luận: đo α từ thống kê corpus (H3) không hơn `logspace` ; ưu thế token hoá âm tiết (H2) mới là dấu hiệu; recall tầm xa vẫn là điểm yếu lượng cực của Hyena.

- Đóng góp: so sánh có kiểm soát Hyena–Transformer **đầu tiên trên tiếng Việt** ở quy mô này + trả lời có bằng chứng cho một siêu tham số bài báo gốc không đặc tả + hạ tầng tái lập đầy đủ (67 test, cache token, artifact truy ngược được).



— DEMO



Cảm ơn thầy và các bạn!

Nhóm 08 · Nguyễn Cao Trung Kiên · Tô Huỳnh Minh Tiến · Trần Tú Quang

Mã nguồn, 67 phép kiểm và toàn bộ artifact: github.com/KienNguyenDev2711/Hyena-Attention-Study